

Министерство науки и высшего образования РФ
Федеральное государственное автономное
образовательное учреждение высшего образования
«СИБИРСКИЙ ФЕДЕРАЛЬНЫЙ УНИВЕРСИТЕТ»

Гуманитарный институт
Кафедра информационных технологий
в креативных и культурных индустриях

**ОТЧЕТ О ТЕХНОЛОГИЧЕСКОЙ
(ПРОЕКТНО-ТЕХНОЛОГИЧЕСКОЙ) ПРАКТИКЕ**

Формирование корпуса отчетов губернаторов Енисейской губернии: опыт
автоматизации разметки текстов с использованием ИИ-инструментов

Руководитель

Л.М.Анатольевна

Студент

ГФ25-01Б

М.Э.Ровшанович

Красноярск 2026

РЕФЕРАТ

Отчет о технологической практике по теме «Формирование корпуса отчетов губернаторов Енисейской губернии: опыт автоматизации разметки текстов с использованием ИИ-инструментов» содержит сведения об апробации автоматизированного пайплайна на материале портала GovReport Сибирского федерального университета.

Ключевые слова: TEI XML, исторический корпус, Енисейская губерния, автоматизированная разметка, хронологические маркеры, верификация данных, реестр сущностей, CSV, XML.

Индивидуальное задание заключалось в экспертной верификации результатов автоматической разметки текстового массива, исправлении хронологических маркеров и систематизации именованных сущностей. Цель работы — апробировать элементы ИИ-пайплайна на этапе верификации данных, выполнив ручную коррекцию дат в TEI XML и упорядочив извлеченные сущности в таблицах.

Для достижения цели решены задачи:

- проанализировать автоматическую разметку дат в формате TEI XML;
- провести экспертную верификацию и ручную доработку дат в отчете за 1851 год со связыванием их с событиями через атрибут ref;
- извлечь и нормализовать упоминания антропонимов и топонимов в таблицах.
- исправить теги автоматического разметчика;

Итогом практики стали: верифицированный документ 1851_final_marked.xml со сквозной привязкой дат к событиям, а также структурированные реестры "Города ТС.csv" и "Имена ТС.csv" с нормализованными сущностями. Практическая значимость состоит в повышении точности работы ИИ-инструментов на основе разработанной методики ручной валидации данных.

ВВЕДЕНИЕ

В современной цифровой гуманитаристике (*Digital Humanities*) переход от простых цифровых копий исторических источников (сканов или OCR-текстов) к полноценным исследовательским корпусам требует применения стандартизированной разметки. Международный стандарт TEI XML позволяет преобразовывать тексты в машиночитаемый вид, детально описывая как структуру документа, так и семантические элементы: имена, географические объекты, организации и даты [1]. Это создает основу для автоматизированного поиска и количественного анализа данных.

Проблема исследования. Корпус отчетов губернаторов Енисейской губернии XIX века обладает высокой исторической ценностью, однако его автоматическая обработка ИИ-инструментами затруднена. Дореформенная орфография, сложные административные формулы и специфическая лексика приводят к ошибкам алгоритмов распознавания сущностей (NER) и некорректной привязке хронологических маркеров. В связи с этим возникает необходимость гибридного подхода, при котором первичная автоматическая разметка ИИ проходит обязательный этап экспертного контроля качества, ручной доработки человеком и выгрузки сущностей в чистые аналитические таблицы.

Цель работы - провести верификацию результатов автоматизированного пайплайна разметки исторических документов на материале отчета губернатора Енисейской губернии за 1851 год, осуществить ручную доразметку и очистку временных маркеров в формате TEI XML со связыванием их с реестром событий, а также сформировать нормализованные контрольные реестры извлеченных именованных сущностей в формате CSV.

Для достижения цели были поставлены следующие задачи:

-Изучить принципы структурной и семантической разметки исторических источников в стандарте TEI XML;

-Осуществить сплошную проверку качества автоматической разметки именованных сущностей в тексте отчета за 1851 год и вручную устранить пропуски и ошибки алгоритмов;

- Систематизировать верифицированные сущности (персоны, топонимы, организации) в виде структурированного реестра в формате CSV;

Объектом исследования является текст отчета губернатора Енисейской губернии за 1851 год, а предметом - методика экспертной валидации и ручной доразметки ИИ-структурированных текстовых массивов.

Методологическую и технологическую основу работы составили методы источниковедческого анализа, принципы корпусной лингвистики, международный стандарт разметки TEI P5, язык XML, а также формат CSV для упорядочивания табличных данных.

Гипотеза работы заключается в том, что экспертный контроль и ручная доразметка ИИ-текстов позволяют полностью компенсировать ошибки автоматического анализа исторических документов, существенно повышая точность финального цифрового корпуса и подготавливая надежную базу для историко-гуманитарной аналитики.

1 МЕТОДИКА ЭКСПЕРТНОЙ ВЕРИФИКАЦИИ И РУЧНОЙ ДОРАЗМЕТКИ ТЕКСТА

1.1 Анализ качества первичной автоматической разметки

На данном этапе исследования был взят текстовый массив всеподданнейшего отчета губернатора Енисейской губернии за 1851 год, прошедший первичную обработку автоматизированным ИИ-пайплайном. Целью анализа было проведение экспертного контроля качества для проверки полноты извлечения фактографических данных (персон, топонимов, организаций) и выявления возможных пропусков алгоритмов при разметке хронологических показателей.

В ходе сплошной верификации текста было установлено... Основные задачи верификации свелись к:

- **Поиск пропущенных хронологических маркеров:** Выявление единичных случаев, когда цифры годов или контекстные указания на время не были обернуты автоматическим скриптом в соответствующие теги.
- **Проверка контекстных связей (ref-ссылок):** Контроль правильности соотнесения дат с конкретными историческими процессами и событиями, описанными в тексте отчета. Это осуществлялось путем проверки и ручного добавления атрибута ref в теги дат для исключения логических сдвигов в базе данных.

1.2 Процесс ручной корректировки TEI XML-кода

Для исправления ошибок была проведена сплошная ручная доразметка документа 1851_final_marked.xml в соответствии со стандартами консорциума TEI (Text Encoding Initiative). Работа строилась по следующему алгоритму:

- **Валидация тегов:** Восстановление пропущенных или некорректно закрытых тегов структурных элементов документа.
- **Точечная семантическая разметка:** Вручную размечались пропущенные сущности с использованием строгого синтаксиса стандарта TEI XML:
 - Персоны: `<persName>...</persName>`
 - Географические объекты: `<placeName>...</placeName>`
 - Организации и ведомства: `<orgName>...</orgName>`
 - Даты и временные маркеры: `<date when="..." ref="...">...</date>`

1.3 Систематизация сущностей в таблицах CSV

Помимо работы с XML-кодом, важной частью практики стало упорядочивание встреченных в отчете названий и имен в отдельные файлы. Результатом этой работы стали две таблицы:

1. "Города ТС.csv" - реестр из 37 географических объектов (городов, округов, рек). В таблице зафиксировано, как объект написан в самом тексте отчета, указано его стандартное название в именительном падеже, а также определен его тип или административный статус.

2. "Имена ТС.csv" - реестр из 140 исторических персон. Для каждого имени проведена нормализация (приведение к именительному падежу) и на основе контекста определена социальная роль, сословие или должность человека (например, купец, мещанин, губернатор).

2 РЕФЛЕКСИЯ И АНАЛИЗ ПОЛУЧЕННЫХ НАВЫКОВ

2.1 Суть проекта и личный вклад

В ходе прохождения практики я принимал участие в научно-исследовательском проекте Провалинского Владимира и Карповича Александра под руководством научного руководителя Нигматуллина Ильи Рафаильевича. Данный проект посвящен созданию цифрового корпуса отчетов губернаторов Енисейской губернии. Его суть заключается в том, чтобы перевести архивные документы (сканы и распознанный текст) в современный машиночитаемый формат TEI XML. Это необходимо для того, чтобы историки могли оперативно искать нужную информацию, визуализировать данные и проводить компьютерный анализ текстов.

Моя личная работа в проекте строилась на этапе контроля качества автоматической разметки. Я работал с конкретным историческим документом - отчетом Енисейского гражданского губернатора за 1851 год. Моя задача состояла в том, чтобы:

- Проверить XML-код после автоматического скрипта и вручную доразметить пропущенные им элементы.
- Собрать две независимые таблицы - «Города ТС.csv» и «Имена ТС.csv», приведя все названия и имена к стандартному именительному падежу и классифицировав их по типам и социальным ролям.

В процессе выполнения этой работы я прошёл важный этап адаптации. Изначально, открыв первично размеченный документ, было сложно оперативно считывать структуру TEI XML из-за высокой плотности тегов. Однако по мере погружения в материал у меня сформировалось понимание логики разметки: синтаксис кода стал понятным, и я начал замечать неточности и пропущенные автоматическим скриптом сущности.

Для меня, как для студента первого курса, участие в верификации реального архивного корпуса стало серьёзным и увлекательным вызовом. Работа с международным стандартом TEI XML дала ощущение причастности к сложным, продвинутым технологиям на стыке истории и IT (Digital Humanities), к которым на начальном этапе обучения редко удаётся прикоснуться. Это не только развило мою внимательность к деталям при работе с кодом, но и подтвердило важность концепции, где человеческий опыт дополняет и корректирует возможности искусственного интеллекта.

ЗАКЛЮЧЕНИЕ

В ходе прохождения технологической (проектно-технологической) практики были в полном объёме выполнены поставленные задачи и достигнута главная цель - апробация элементов автоматизированного пайплайна обработки исторических документов на этапе экспертной верификации качества данных.

На основании проделанной работы можно сделать следующие выводы:

1. Применение ИИ-инструментов для первичного анализа текстов XIX века значительно ускоряет процесс формирования цифровых корпусов,

однако специфика исторических источников обуславливает необходимость обязательного контроля.

2. В ходе сплошной ручной верификации всеподданнейшего отчёта губернатора Енисейской губернии за 1851 год были успешно устранены пропуски автоматического парсера.
3. Систематизация и нормализация извлечённых сущностей позволили сформировать два чистых структурированных реестра («Города ТС.csv» и «Имена ТС.csv»), содержащих 37 географических объектов и 140 исторических персоналий, приведённых к именительному падежу с указанием их административного и социального статусов.

Практический опыт показал, что гибридный подход, совмещающий скорость алгоритмов искусственного интеллекта и экспертный анализ человека, позволяет компенсировать ошибки автоматического распознавания (NER). Это обеспечивает создание достоверной и репрезентативной основы для дальнейших компьютерных и статистических исследований в области цифровой гуманитаристики (Digital Humanities).

